

Porównanie działania wybranych algorytmów minimalizacji stochastycznej

Kacper Feliks, Maciej Wiśniewski

28-01-2025

Cel projektu

Projekt polega na prostym opracowaniu statystycznym wyników porównania działania wybranych algorytmów minimalizacji stochastycznej. Zdecydowaliśmy się do porównania użyć następujących algorytmów:

- **Poszukiwanie przypadkowe (Pure Random Search, PRS)**

- **Metoda wielokrotnego startu (multi-start, MS)**

Opis algorytmów

Poszukiwanie przypadkowe (Pure Random Search, PRS)

Algorytm PRS polega na losowym przeszukiwaniu przestrzeni rozwiązań, w której minimalizowana funkcja jest zdefiniowana. Działa w następujący sposób:

1. **Losowanie punktów:** Losujemy kolejne punkty w przestrzeni poszukiwań z rozkładu jednostajnego. Jeżeli dziedzina poszukiwań jest kostką wielowymiarową, to każdą współrzędną punktu losujemy z odpowiedniego jednowymiarowego rozkładu jednostajnego.
Na przykład, jeśli dziedzina poszukiwań to kostka trójwymiarowa $[0, 1] \times [-2, 2] \times [100, 1000]$, losowanie współrzędnych wygląda następująco:
 - pierwsza współrzędna: $U(0, 1)$,
 - druga współrzędna: $U(-2, 2)$,
 - trzecia współrzędna: $U(100, 1000)$.
2. **Porównanie wartości funkcji:** Wartość funkcji w każdym wylosowanym punkcie porównujemy z aktualnie zapamiętanym minimum. Jeśli wartość funkcji w nowym punkcie jest mniejsza, zapamiętujemy ten punkt jako nowe minimum.
3. **Wynik:** Wartość funkcji w ostatnim zapamiętanym punkcie stanowi wynik algorytmu.

Metoda wielokrotnego startu (Multi-Start, MS)

Algorytm **MS** łączy losowe przeszukiwanie przestrzeni z metodami optymalizacji lokalnej. Jego kroki są następujące:

1. **Losowanie punktów:** Podobnie jak w **PRS**, losujemy zadany zbiór punktów startowych z rozkładu jednostajnego w przestrzeni poszukiwań.
2. **Uruchomienie optymalizacji lokalnej:** Dla każdego wylosowanego punktu startowego uruchamiana jest metoda optymalizacji lokalnej.
3. **Porównanie wyników:** Dla każdego startu zapisujemy wartość funkcji w zwróconym punkcie lokalnego minimum. Wynikiem algorytmu jest minimalna wartość funkcji spośród wszystkich punktów końcowych.

Do porównania należało wybrać dwie z funkcji dostępnych w pakiecie **smoof**, które są skalarne (single-objective) i mają wersje dla różnej liczby wymiarów (akceptują parametr **dimensions**).

W celu sprawdzenia dostępnych algorytmów wykonaliśmy następujący algorytm, który znajdował dostępne funkcje o wymaganych parametrach:

```
library(smoof)

scalar_dimensional_functions <- Filter(function(fn_name) {
  fn <- get(fn_name, envir = asNamespace('smoof'))
  is.function(fn) &&
  'dimensions' %in% names(formals(fn)) &&
  inherits(try(fn(2), silent = TRUE), 'smoof_function') &&
  getNumberOfObjectives(fn(2)) == 1
}, ls('package:smoof'))

print(scalar_dimensional_functions)
```

Do porównania wybraliśmy dwie funkcje:

- **Griewank**
- **Schwefel**

Nasz wybór padł dokładnie na te funkcje ze względu na nich odmiennność, trudność w optymalizacji oraz niebanalną impelmentację.

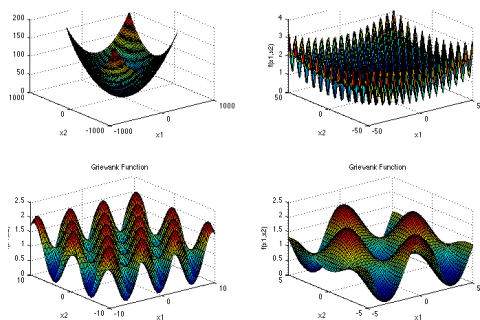
Funkcja Griewanka

Funkcja Griewanka ma wiele szeroko rozposzechnionych minimów lokalnych, które są regularnie dystrybuowane. Wzór funkcji:

$$f(\mathbf{x}) = \sum_{i=1}^d \frac{x_i^2}{4000} - \prod_{i=1}^d \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1$$

gdzie przez d rozumiemy ilość wymiarów. Funkcja jest zazwyczaj definiowana na hipersześcianach $x_i \in [-600, 600]$, dla każdego $i = 1, \dots, d$.

Minimum globalne $f(\mathbf{x}^*) = 0$, dla $\mathbf{x}^* = (0, \dots, 0)$



Wizualizacja funkcji Griewanka w 3D


Funkcja Schwefela

Funkcja Schwefela jest złożoną funkcją, posiadającą wiele minimów lokalnych. Wzór funkcji:

$$f(\mathbf{x}) = \sum_{i=1}^n -x_i \sin\left(\sqrt{|x_i|}\right)$$

gdzie przez d rozumiemy ilość wymiarów. Funkcja jest zazwyczaj definiowana na hipersześcianach $x_i \in [-500, 500]$, dla każdego $i = 1, \dots, d$.

Minimum globalne $f(\mathbf{x}^*) = 418.9829 * d$, dla $\mathbf{x}^* = (420.9687, \dots, 420.9687)$



Reprezentacja funkcji Schwefela w przestrzeni 3D

Specyfikacja sprzętu

Obliczenia i testy zostały wykonane na komputerze o następującej specyfikacji:

- system Windows 10
- procesor Intel Core i7-6700HQ 2.60 GHz.
- pamięć Ram 16Gb

WYNIKI

Funkcja Griewanka 2D

| Miara | MS | PRS |
|---------------------|-----------|-----------|
| Średnia | 0.6055442 | 0.6434122 |
| Wartość najmniejsza | 0.007396 | 0.0373963 |
| Wartość największa | 4.4481658 | 1.7034647 |
| Mediana | 0.3253765 | 0.6161477 |
| Dolny kwartyl (25%) | 0.1257573 | 0.4292943 |
| Górny kwartyl (75%) | 0.8310025 | 0.8541051 |

Funkcja Griewanka 10D

| Miara | MS | PRS |
|---------------------|-----------------------------|------------|
| Średnia | $5.3433198 \times 10^{-11}$ | 51.7091663 |
| Wartość najmniejsza | $1.3820056 \times 10^{-12}$ | 12.0229676 |
| Wartość największa | $2.1964297 \times 10^{-10}$ | 83.9943267 |
| Mediana | $4.1341264 \times 10^{-11}$ | 51.6668436 |
| Dolny kwartyl (25%) | $2.7560176 \times 10^{-11}$ | 43.7718444 |
| Górny kwartyl (75%) | $7.4529827 \times 10^{-11}$ | 61.4505366 |

Funkcja Griewanka 20D

| Miara | MS | PRS |
|---------------------|-----------------------------|-------------|
| Średnia | $8.1357054 \times 10^{-11}$ | 222.7744787 |
| Wartość najmniejsza | $1.3866686 \times 10^{-13}$ | 138.0348086 |
| Wartość największa | $1.7841773 \times 10^{-10}$ | 271.2005696 |
| Mediana | $7.5553341 \times 10^{-11}$ | 223.940142 |
| Dolny kwartyl (25%) | $5.6181226 \times 10^{-11}$ | 207.9649149 |
| Górny kwartyl (75%) | $1.0998349 \times 10^{-10}$ | 239.8048899 |

Funkcja Schwefela 2D

| Miara | MS | PRS |
|---------------------|--------------|--------------|
| Średnia | -836.7813912 | -797.1918759 |
| Wartość najmniejsza | -837.9657745 | -836.5685042 |
| Wartość największa | -719.5274399 | -643.5621982 |
| Mediana | -837.9657745 | -804.2280449 |
| Dolny kwartyl (25%) | -837.9657745 | -823.5638115 |
| Górny kwartyl (75%) | -837.9657745 | -781.6197479 |

Funkcja Schwefela 10D

| Miara | MS | PRS |
|---------------------|---------------|---------------|
| Średnia | -3262.1275223 | -1990.2290063 |
| Wartość najmniejsza | -3716.0755343 | -2648.5365291 |
| Wartość największa | -2923.4470726 | -1671.7495182 |
| Mediana | -3259.0250766 | -1977.0998535 |
| Dolny kwartyl (25%) | -3378.9804707 | -2101.5557137 |
| Górny kwartyl (75%) | -3142.8476519 | -1880.3428427 |


Funkcja Schwefela 20D

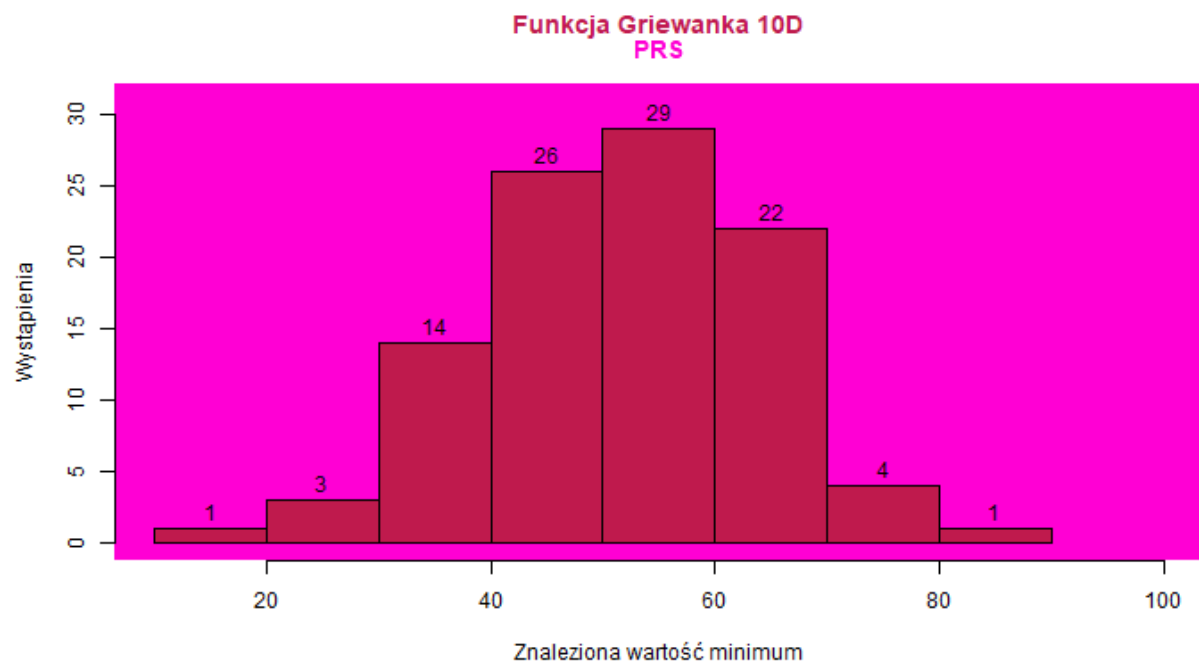

| Miara | MS | PRS |
|---------------------|---------------|---------------|
| Średnia | -5930.2842622 | -2871.2092706 |
| Wartość najmniejsza | -6721.5020158 | -3883.630182 |
| Wartość największa | -5415.4216596 | -2404.6476755 |
| Mediana | -5927.3537852 | -2845.6522752 |
| Dolny kwartyl (25%) | -6073.1127276 | -3018.7275952 |
| Górny kwartyl (75%) | -5732.1016643 | -2683.1582378 |

Funkcja Griewanka 2D
MS




Funkcja Griewanka 2D
PRS






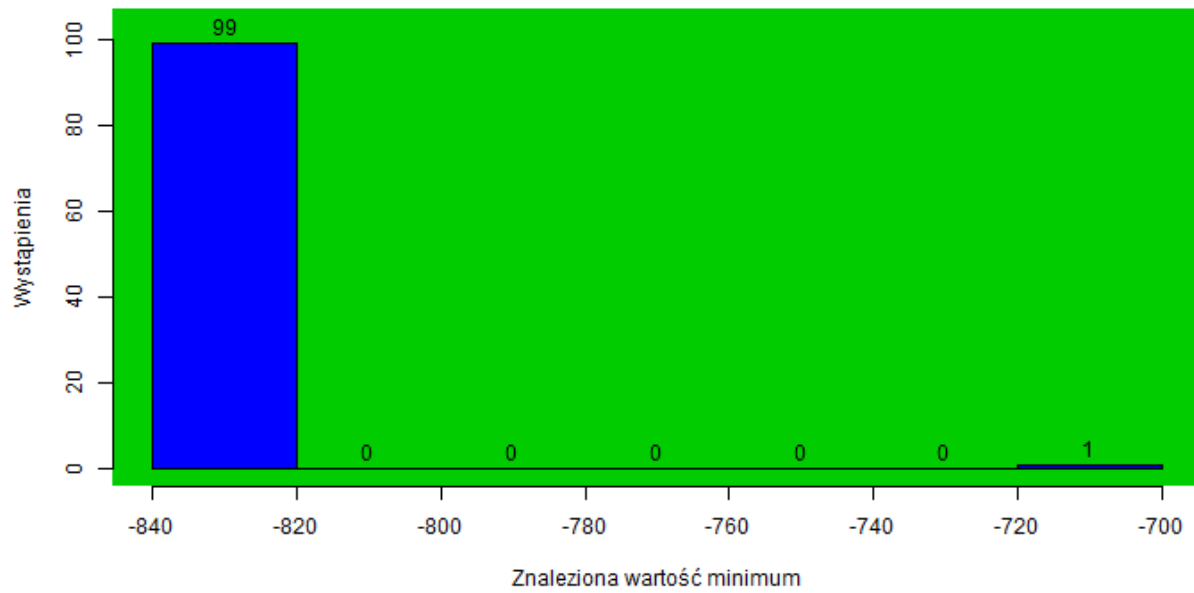
Funkcja Griewanka 20D
MS




Funkcja Griewanka 20D
PRS




Funkcja Schwefela 2D
MS



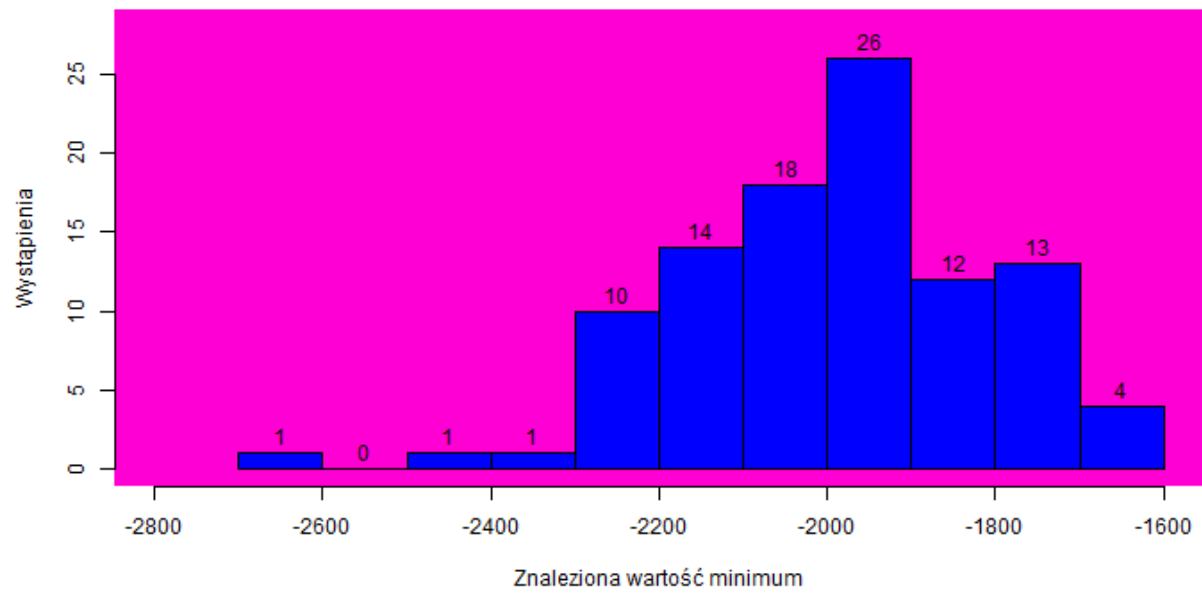
Funkcja Schwefela 2D
PRS




Funkcja Schwefela 10D
MS




Funkcja Schwefela 10D
PRS




Funkcja Schwefela 20D
MS




Funkcja Schwefela 20D
PRS




Wykresy pudełkowe




Funkcja Griewanka, 10D




Funkcja Griewanka, 20D




Funkcja Schwefela, 2D



Funkcja Schwefela, 10D



Funkcja Schwefela, 20D



T testy

Dla hipotezy zerowej twierdzącej, że średnie są sobie równe

Funkcja Griewanka, 2D

```
##
## Paired t-test
##
## data: G2PRS and G2MS
## t = 0.51955, df = 99, p-value = 0.6045
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## -0.1067528 0.1824889
## sample estimates:
## mean difference
## 0.03786802
```

Funkcja Griewanka, 10D

```
##
## Paired t-test
##
## data: G10PRS and G10MS
## t = 40.75, df = 99, p-value < 2.2e-16
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## 49.19135 54.22699
## sample estimates:
## mean difference
## 51.70917
```

Funkcja Griewanka, 20D

```
##
## Paired t-test
##
## data: G20PRS and G20MS
## t = 87.939, df = 99, p-value < 2.2e-16
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## 217.7479 227.8011
## sample estimates:
## mean difference
## 222.7745
```

Funkcja Schwefela, 2D

```
##  
## Paired t-test  
##  
## data: S2PRS and S2MS  
## t = 10.624, df = 99, p-value < 2.2e-16  
## alternative hypothesis: true mean difference is not equal to 0  
## 95 percent confidence interval:  
## 32.19550 46.98353  
## sample estimates:  
## mean difference  
## 39.58952
```

Funkcja Schwefela, 10D

```
##  
## Paired t-test  
##  
## data: S10PRS and S10MS  
## t = 56.898, df = 99, p-value < 2.2e-16  
## alternative hypothesis: true mean difference is not equal to 0  
## 95 percent confidence interval:  
## 1227.543 1316.254  
## sample estimates:  
## mean difference  
## 1271.899
```

Funkcja Schwefela, 20D

```
##  
## Paired t-test  
##  
## data: S20PRS and S20MS  
## t = 91.343, df = 99, p-value < 2.2e-16  
## alternative hypothesis: true mean difference is not equal to 0  
## 95 percent confidence interval:  
## 2992.623 3125.527  
## sample estimates:  
## mean difference  
## 3059.075
```

Wnioski podsumowujące:

Funkcja Schwefela wykazuje większe różnice między algorytmami niż funkcja Griewanka. Dla funkcji Griewanka w 2D nie zaobserwowano istotnej różnicy między algorytmami, ale dla wyższych wymiarów (10D, 20D) MS osiąga znacząco lepsze wyniki niż PRS. W przypadku funkcji Schwefela, która charakteryzuje się trudnymi krajobrazami z wieloma lokalnymi minimami, metoda MS znacznie lepiej radzi sobie z eksplorowaniem przestrzeni poszukiwań i znajdowaniem głębszych minimów. Z kolei PRS wykazuje pewne trudności w bardziej złożonych przestrzeniach, co prowadzi do większych różnic w wynikach w wymiarach wyższych niż 2D.

W funkcji Schwefela dla 10D i 20D różnice między algorytmami stają się wyraźniejsze, ponieważ w tych wymiarach przestrzeń staje się bardziej złożona. Różnice w wynikach są statystycznie istotne, co wskazuje na większą efektywność MS w radzeniu sobie z trudnymi funkcjami optymalizacyjnymi w wyższych wymiarach. Wraz ze wzrostem liczby wymiarów, różnica między algorytmami staje się coraz bardziej wyraźna. Przewaga MS nad PRS rośnie wykładniczo wraz z wymiarowością. Testy statystyczne (t-test) oraz średnie różnice wskazują, że algorytmy różnią się w sposobie rozwiązywania problemu.